

TermiGraph

Terminología en RDF

DOCUMENTACIÓN TERMIGRAPH: CONVERSOR DE GLOSARIOS MONOLINGÜES

23 de abril de 2026

TerésIA



Índice

1. Introducción	2
2. Estructura del glosario monolingüe	2
3. TermiGraph paso a paso	2
3.1. Paso 1: Cargar el recurso	3
3.2. Paso 2: Indicar los metadatos del recurso	3
3.3. Paso 3: Descarga del archivo	5
4. Terminología en RDF con Ontolex-lemon	5
4.1. Web Semántica y RDF	6
4.2. Datos terminológicos y el modelo Ontolex-lemon	6
4.3. Modelo de transformación de TeresIA	7
A. Ejemplo de datos transformados	I

1. INTRODUCCIÓN

El presente documento describe el uso y funcionamiento de TermiGraph¹, un conversor de terminologías a RDF desarrollado en el marco del proyecto nacional Teresia², cuyo objetivo es proporcionar un punto centralizado de acceso a terminologías.

El contenido se centra específicamente en la conversión de glosarios monolingües. En la sección 2 se detalla cómo deben estructurarse los datos de entrada que el usuario desea transformar. En la sección 3 se ofrece una guía paso a paso para utilizar la interfaz de conversión. Finalmente, la sección 4 introduce brevemente el concepto de datos enlazados y explica cómo se representan en RDF los datos originales tras la transformación.

2. ESTRUCTURA DEL GLOSARIO MONOLINGÜE

Este conversor requiere como entrada un archivo de texto plano (es decir, un fichero con extensión *.txt*). En cuanto a la estructura de los datos, cada término debe aparecer en una línea independiente. Tal como se muestra en la Figura 1, **no debe añadirse ningún signo de puntuación al final de las líneas**, ya que el conversor utiliza los saltos de línea para identificar y separar los términos. Cualquier signo de puntuación incluido al final será interpretado como parte del término. Del mismo modo, no debe incorporarse información adicional más allá del propio término.




Figura 1: Ejemplo de glosario monolingüe

3. TERMIGRAPH PASO A PASO

A continuación, se explica paso a paso cómo convertir un glosario monolingüe con TermiGraph.

¹<https://termigraph.teresia.linkeddata.es>

²<https://proyectoteresia.org/>

3.1. Paso 1: Cargar el recurso

Paso 1: CARGA DEL RECURSO

Tipo de archivo: *

-- Selecciona un tipo --

Archivo: *

Examinar...

No se ha seleccionado ningún archivo.

Limpiar

Continuar

* Obligatorio

Figura 2: TermiGraph paso 1 (carga del recurso)

Tal y como se muestra en la Figura 2, en la primera pantalla del conversor se ha de cargar el recurso que se quiera convertir, indicando su tipo.

Para ello, primero se debe indicar el *Tipo de archivo*. Esta selección condicionará el conversor que se quiere utilizar. En el caso de los glosarios monolingües, se debe seleccionar ‘**Glosario monolingüe (lista)**’.

A continuación, en *Archivo*, se debe cargar **cargar el fichero** a convertir. Para ello, pulse ‘Examinar’. Es importante tener en cuenta que dicho fichero debe estar en formato de texto plano, es decir, debe tener la **extensión .txt**. Asimismo, tal y como se explica en la Sección 2, **cada línea** debe contener **un sólo término, sin signos de puntuación** (salvo que sean parte del término).

Una vez se haya cumplimentado la primera página, pulse ‘Continuar’. En caso de querer borrar los datos, puede pulsar ‘Limpiar’.

3.2. Paso 2: Indicar los metadatos del recurso

A través de la segunda página del conversor se registran los metadatos del glosario (ver Figura 3).

En primer lugar, es obligatorio introducir el nombre del recurso en el campo *Título del recurso*.

A continuación, debe especificarse el idioma del glosario en el campo *Idioma del recurso*. Dado que se trata de un recurso monolingüe, solo se admite un idioma. El idioma introducido por el usuario será buscado en Lexvo³, una ontología que identifica un gran número de lenguas y sus respectivas etiquetas en distintos idiomas. Para asegurar una conversión correcta, **se recomienda indicar el idioma mediante su código ISO o su nombre oficial en español o en inglés**, ya que estos valores presentan mayor cobertura en Lexvo. En caso de que el idioma no se encuentre en

³<http://www.lexvo.org/>

Paso 2: METADATOS DEL RECURSO

Título del recurso *

Idioma del recurso *

Dominio (EuroVoc) *

Buscar...

DERECHO

derechos y libertades

derechos políticos

derechos sociales

derechos fundamentales

lucha contra la discriminación

Autor del recurso *

Nota: Para añadir múltiples autores, separar mediante punto y coma (;). Por ejemplo: Marta López; Juanito García

Enlace al recurso original

Limpiar

Convertir

* Obligatorio

Figura 3: TermiGraph paso 2 (metadatos del recurso)

dicha ontología, se conservará tal y como lo haya introducido el usuario.

Seguidamente, en el campo *Dominio (EuroVoc)*, se deben seleccionar uno o varios dominios temáticos relacionados con el glosario. Dado que TermiGraph ha sido desarrollada en coherencia con los demás servicios de TeresIA, las opciones disponibles se han limitado para facilitar la posterior desambiguación de términos. En particular, se emplea el esquema establecido por EuroVoc⁴, el tesoro multidisciplinario de la Unión Europea.

En el campo *Autor del recurso*, de carácter obligatorio, se debe indicar el autor o los autores del glosario. Tal como se señala en la nota, **si existen varios autores, deben separarse mediante punto y coma (;)**. Por ejemplo: Marcela Sánchez Giménez; Pedro López Rosas. Cabe destacar que, al convertirse los datos en un grafo interconectado, no se conserva ningún orden jerárquico entre los autores.

⁴<https://eur-lex.europa.eu/browse/eurovoc.html?locale=es>

De forma opcional, puede añadirse un enlace al recurso original en el campo *Enlace al recurso original*. Aunque no es obligatorio, se recomienda completarlo para aumentar la visibilidad del glosario, especialmente si se prevé su incorporación al portal de TeresIA.

Una vez completados todos los metadatos, se puede proceder a la conversión del recurso pulsando el botón *Convertir*. Si se desea eliminar la información introducida, puede utilizarse la opción *Limpiar*.

3.3. Paso 3: Descarga del archivo




Figura 4: TermiGraph paso 3 (descarga)

Mientras el glosario se convierte, un mensaje de espera aparecerá en pantalla. El conversor puede tardar varios minutos en convertir el recurso, especialmente si el recurso es grande.

Finalmente, cuando el proceso de conversión se completa correctamente, el archivo resultante puede descargarse pulsando en *Descargar archivo*.

En caso de querer añadir su recurso al portal de recursos de TeresIA, puede enviar el recurso convertido al correo electrónico que se ofrece como contacto. Asimismo, se recomienda incluir en el mensaje una breve descripción del recurso, para los usuarios del portal. Se recuerda que, debido a la naturaleza del proyecto, **solo se aceptarán recursos que incluyan alguno de los idiomas oficiales de España**.

En caso de querer convertir un nuevo recurso, es posible volver a la primera página del conversor pulsando en *Convertir otro*.

4. TERMINOLOGÍA EN RDF CON ONTOLEX-LEMON

Esta sección tiene como objetivo explicar la estructura del archivo RDF generado. Para ello, se inicia con una breve introducción a la Web Semántica, al estándar RDF y a varios conceptos fundamentales que facilitan su comprensión. A continuación, se presenta el modelo Ontolex-lemon, el modelo de referencia para la representación de datos lingüísticos y la base empleada en TeresIA

para la transformación de los términos. Finalmente, se describe la estructura del RDF resultante, detallando cómo se representan los términos originales en el modelo transformado.

4.1. Web Semántica y RDF

El RDF (Resource Description Framework)⁵ es un formato estándar propuesto por World Wide Web Consortium (W3C) y sirve como base de los datos enlazados. Este formato organiza la información en tripletas compuestas por un sujeto, un predicado y un objeto; y el conjunto de tripletas genera un grafo. El sujeto, que es el primer elemento de la tripleta, representa el recurso sobre el cual se proporciona información y se identifica mediante un Identificador Uniforme de Recursos (URI, por sus siglas en inglés). El predicado, que ocupa la segunda posición, describe la relación o propiedad que conecta al sujeto con el objeto, siendo también representado por un URI. Por último, el objeto, tercer elemento de la tripleta, define el valor asociado a la propiedad del sujeto, pudiendo ser un literal (como texto) o un URI.(Chaves-Fraga et al., 2022)

Para estandarizar la representación de datos, se utilizan las ontologías, que son modelos o esquemas semánticos diseñados para describir formalmente un dominio. Las ontologías incluyen diversos componentes, como clases, propiedades e instancias. Las clases definen categorías o tipos de elementos dentro de un ámbito de conocimiento. Las propiedades representan las relaciones o atributos que vinculan clases o instancias entre sí. Por último, las instancias son ejemplos concretos o específicos que forman parte de una clase.

1. Sujeto: es aquello de lo que se habla, el recurso principal de la afirmación.
2. Predicado: es la propiedad o relación que conecta al sujeto con algo más.
3. Objeto: es el valor o recurso que completa el significado de la relación establecida por el predicado.

4.2. Datos terminológicos y el modelo Ontolex-lemon

Aunque no hay una sola forma de representar los datos lingüísticos en RDF, Ontolex-lemon (en adelante, Ontolex) (McCrae et al., 2017) se ha convertido en la ontología o modelo más utilizado para representar recursos lexicográficos y terminológicos en RDF (Cimiano et al. 2011, Di Buono et al. 2020). Esta ontología cuenta con cuatro clases principales, tal y como se puede observar en la Figura 5: Concepto Léxico (*Lexical Concept*), Sentido Léxico (*Lexical Sense*), Entrada Léxica (*Lexical Entry*) y Forma (*Form*). La clase Entrada Léxica se utiliza para representar una palabra, frase o unidad léxica en una lengua determinada. Las diferentes realizaciones morfológicas de la entrada se expresan a través de la clase Forma. En cuanto al Sentido Léxico, se utiliza para proporcionar una conexión semántica entre la Entrada Léxica y un concepto de la ontología. Por último, un Concepto Léxico representa un concepto o idea abstracta que unifica significados entre sentidos léxicos y lenguas.

Aunque Ontolex cubre la mayoría de las necesidades de representación que necesitan los glosarios monolingües, se utilizan otras ontologías para la representación de algunos aspectos como los idiomas o los datos de autoría. En concreto, se usan:

⁵<https://www.w3.org/RDF/>




Figura 5: Diagrama del núcleo de Ontolex

1. **Simple Knowledge Organization System (SKOS)**⁶: un estándar del W3C, utilizado habitualmente para representar datos jerárquicos en tesauros, sistemas de clasificación u otros tipos de sistemas de organización.
2. **Lexvo**⁷: Lexvo.org (de Melo, 2015) es una plataforma de datos enlazados que proporciona identificadores únicos y descripciones semánticas de lenguas y variantes lingüísticas. Su objetivo es vincular información lingüística de diferentes fuentes y ofrecerla en múltiples idiomas para apoyar la interoperabilidad y la reutilización de datos en la Web Semántica.
3. **Meta-Share**⁸: ontología que describe recursos lingüísticos y tecnologías de procesamiento del lenguaje, incluyendo sus propiedades, tipos, relaciones y condiciones de uso.
4. **FOAF (Friend of a Friend)**⁹: ontología usada para describir a las personas, sus actividades y sus relaciones.
5. **DCMI Metadata Terms**¹⁰: vocabulario muy extendido para describir metadatos sobre recursos, como documentos, imágenes, conjuntos de datos o cualquier otro tipo de entidad digital o física. Por ejemplo, permite representar datos como el título o el idioma de un elemento. Esta ontología también se conoce como Dublin Core Terms (DCTerms).
6. **RDF Schema (RDFS)**¹¹: una extensión de vocabulario de RDF que proporciona mecanismos para describir la estructura, la semántica y las relaciones de los datos. Este vocabulario, en este trabajo, se utiliza principalmente para describir los tipos de datos de los objetos de una tripleta.

4.3. Modelo de transformación de TeresIA

Siguiendo el modelo de Ontolex, en el proceso de transformación de los datos terminológicos se generan cuatro clases principales: la Forma, la Entrada Léxica, el Sentido Léxico y el Concepto

⁶<https://www.w3.org/2009/08/skos-reference/skos.html>

⁷<http://www.lexvo.org/>

⁸<http://w3id.org/meta-share/meta-share/2.0.0>

⁹<https://xmlns.com/foaf/spec/>

¹⁰<http://purl.org/dc/terms/>

¹¹<http://www.w3.org/2000/01/rdf-schema#>

Léxico, tal y como se muestra en la Figura 10.




Figura 6: Representación de un glosario monolingüe en Ontolex

Por cada término del glosario se genera una **Forma** (`ontolex:Form`), a la que se asocia su forma escrita mediante la propiedad `ontolex:writtenRep`. Asimismo, se enlaza con el recurso original mediante la propiedad `dct:source`.

Cada Forma está conectada con una **Entrada Léxica** (`ontolex:LexicalEntry`). En esta clase se indica el idioma especificado por el usuario en el formulario de TermiGraph (véase la Sección 3.2). Para representar el idioma se emplea la propiedad `dct:language`, que normalmente enlaza con una URI de Lexvo, favoreciendo así la estandarización y la interoperabilidad. De este modo, independientemente de si el usuario introduce `es`, `spa`, `spanish` o `español`, el valor final corresponderá a la URI del español en Lexvo¹². Esta normalización solo es posible cuando el valor introducido coincide con alguna etiqueta (`rdfs:label`) registrada en Lexvo; en caso contrario, se conserva el valor textual original. La Entrada Léxica también enlaza con el recurso original mediante `dct:source`.

Por cada término se genera además un **Sentido Léxico** (`ontolex:LexicalSense`). Esta clase suele emplearse para representar relaciones entre términos (por ejemplo, sinonimia o traducción), información sobre su ciclo de vida (como si un término está obsoleto) o su fiabilidad. Sin embargo, dado que los glosarios monolingües no contienen este tipo de información, el Sentido Léxico permanece vacío. No obstante, mantiene su enlace al recurso original mediante la propiedad `dct:source`.

Asimismo, se crea un **Concepto Léxico** (`ontolex:LexicalConcept`) por cada término. Habitualmente, esta clase alberga definiciones, notas u otra información conceptual, pero en los glosarios monolingües no se dispone de estos datos, por lo que la clase queda sin contenido

¹²<http://www.lexvo.org/id/iso639-3/spa>

terminológico adicional. Al igual que el resto de clases de Ontolex, el Concepto Léxico enlaza también con el recurso original a través de `dct:source`.

Todos los Conceptos Léxicos se agrupan en un **Conjunto de Conceptos** (`ontolex:ConceptSet`) mediante la propiedad `skos:inScheme`. A través de este conjunto se accede al Recurso Léxico-Conceptual (`ms:LexicalConceptualResource`), donde se almacenan los metadatos del recurso.

Los metadatos se describen conforme a la ontología Meta-Share. Para ello, se genera un **Recurso Lexico-Conceptual** (`ms:LexicalConceptualResource`). El nombre del recurso se indica mediante `ms:resourceName`, y el idioma mediante `ms:language`, siguiendo el mismo criterio de estandarización con Lexvo mencionado anteriormente. Como ya se ha mencionado previamente, toda la información representada mediante Ontolex (Forma, Entrada Léxica, Sentido Léxico y Concepto Léxico) enlaza con este recurso para garantizar la trazabilidad de los datos originales en el grafo.

El **dominio temático** del recurso se especifica mediante `ms:domain`, que enlaza con una instancia de EuroVoc (`skos:Concept`). Además, la propiedad `ms:resourceCreator` vincula el recurso con su autor, representado como una instancia de `ms:Actor`, cuyo nombre se indica mediante `rdfs:label`. Finalmente, el enlace al recurso original proporcionado por el usuario se representa mediante `dct:source`.

A. EJEMPLO DE DATOS TRANSFORMADOS

A continuación, se ilustra el proceso de transformación de un recurso. Por un lado, las Figuras 7 y 8 muestran, respectivamente, la carga de un glosario monolingüe en la interfaz de TermiGraph y la posterior cumplimentación de los metadatos del recurso.

Paso 1: CARGA DEL RECURSO

Tipo de archivo: *

Glosario monolingüe (lista)

Archivo: *

Examinar...

ejemplo_glosario.txt

Limpiar

Continuar

* Obligatorio

Paso 2: METADATOS DEL RECURSO

Título del recurso *

Glosario ejemplo

Idioma del recurso *

español

Dominio (EuroVoc) *

Buscar...

DERECHO

derechos y libertades

derechos políticos

derechos sociales

derechos fundamentales

lucha contra la discriminación

[eurovoc:100145] DERECHO ✖

Autor del recurso *

Nota: Para añadir múltiples autores, separar mediante punto y coma (;). Por ejemplo: Marta López; Juanito García

López

Enlace al recurso original

https://original_resource.com/

Limpiar

Convertir

* Obligatorio

Figura 7: Carga de recurso en TermiGraph

Figura 8: Metadatos en TermiGraph

Por otro lado, la Figura 9 muestra el contenido del archivo cargado en la Figura 7.




Figura 9: Ejemplo de un glosario monolingüe

Finalmente, la Figura 10 muestra un diagrama que ejemplifica cómo quedan representados en RDF los datos del recurso una vez transformado.




Figura 10: Diagrama ejemplo de datos convertidos a Ontolex

Referencias

Chaves-Fraga, D., Óscar Corcho, and Ruckhaus, E. (2022). Guía práctica para la publicación de datos enlazados. *datos.gob.es*.

Cimiano, P., Buitelaar, P., McCrae, J., and Sintek, M. (2011). Lexinfo: A declarative model for the lexicon-ontology interface. *Web Semantics: Science, Services and Agents on the World Wide Web*.

de Melo, G. (2015). Lexvo.org: Language-related information for the Linguistic Linked Data cloud. *Semantic Web*, 6(4):393–400.

Di Buono, M. P., Cimiano, P., Elahi, M. F., and Grimm, F. (2020). Terme-a-llod: Simplifying the conversion and hosting of terminological resources as linked data. In *Proceedings of the 7th Workshop on Linked Data in Linguistics (LDL-2020)*, pages 28–35.

McCrae, J. P., Bosque-Gil, J., Gracia, J., Buitelaar, P., and Cimiano, P. (2017). The Ontolex-Lemon model: development and applications. In *Proceedings of eLex 2017 conference*, pages 19–21.